

自然语言处理之文本分类技术综述

A Survey on Text Classification Techniques in Natural Language
Processing

叶浩宇

June 14, 2026

Abstract

文本分类是自然语言处理领域的基石性任务，支撑着垃圾邮件过滤、情感分析、舆情监控、客服工单处理等绝大多数工业级NLP应用。过去六十余年间，文本分类技术经历了规则驱动、统计机器学习、深度学习、预训练语言模型四次重大范式迭代，任务效果与适用边界不断拓展。本文按照“技术演进路线—多维度方法对比—个人深度思考”的逻辑展开梳理：首先沿时间脉络系统拆解三代技术范式的演进背景、核心突破与历史局限；其次从性能、效率、成本、适用场景等多个维度对主流方法开展横向对比；最后结合技术规律与工程实践，提出对领域发展的独立判断与选型建议。本文不追求文献的简单堆砌，而侧重厘清技术发展的内在逻辑，为后续研究与工程落地提供结构化的参考框架。

关键词：自然语言处理；文本分类；技术演进；预训练语言模型；深度学习；方法对比

1 引言与研究背景

自然语言处理的核心目标是让计算机理解人类语言，而文本分类是验证语言理解能力最经典、应用最广泛的任務范式。其本质是根据文本的语义内容，将其自动归入预先定义的一个或多个类别，实现非结构化文本的结构化输出。从早期的垃圾邮件识别，到当下的新闻内容分类、用户评论情感判定、智能客服工单分派，文本分类技术始终是信息检索、内容安全、用户运营等业务场景的核心技术支撑。

从技术发展的宏观视角看，文本分类领域已经完成了三次清晰的范式转移：第一次是从人工规则到统计机器学习，第二次是从传统机器学习到深度学习，第三次是从任务专属模型到预训练大模型。每一次范式迭代，都在解决上一代方法核心痛点的同时，拓展了任务的性能上限与应用边界。

本文将沿着技术发展的时间线梳理演进脉络，对主流方法开展多维度横向对比，并结合工程实践提出个人思考与选型建议，形成一份逻辑清晰、有独立判断的技术综述。

2 文本表示：分类任务的技术基石

文本分类的前提是将人类语言转化为计算机可计算的数值形式，也就是文本表示技术。表示能力的强弱，直接决定了分类模型的性能上限。该领域同样经历了从离散稀疏表示到分布式稠密表示的完整演进，为分类方法的迭代奠定了基础[3]。

2.1 离散稀疏表示阶段

早期文本表示完全基于词频统计，最具代表性的是词袋模型（BoW）与TF-IDF权重。词袋模型将文本视为单词的集合，完全忽略语序与语法，仅统计每个词的出现次数；TF-IDF则在此基础上，通过逆文档频率抑制通用词、凸显特征词，提升表示的区分度。这类方法原理简单、计算高效，但存在天然缺陷：一是丢失了词序与上下文信息，无法区分“我打他”和“他打我”；二是维度灾难，词汇表多大表示向量就有多少维，数据极度稀疏；三是无法衡量词语之间的语义相似度。

尽管存在局限，离散表示至今仍是传统机器学习分类方法的核心特征，在短文本、高实时性场景中依然具备极高的工程价值。

2.2 分布式稠密表示阶段

2013年前后，以Word2Vec、GloVe为代表的词嵌入技术彻底改变了文本表示的范式。基于分布假说——“出现在相似上下文中的词语具有相似的语义”，这类方法将每个词语映射为低维稠密的实数向量，语义相近的词在向量空间中距离更近[5]。

词嵌入第一次让计算机具备了量化语义相似度的能力，解决了离散表示的稀疏性与语义鸿沟问题。但早期的静态词嵌入依然存在明显短板：一个词只有一个向量，无法解决“一词多义”问题。直到预训练语言模型出现，动态上下文嵌入才真正实现了“词随境变”的语义表示，大幅提升了复杂文本的分类效果。

3 文本分类技术演进路线

文本分类技术的演进不是零散方法的堆砌，而是一条清晰的、问题驱动的发展路径。每一代新方法的出现，都是为了解决上一代方法的核心痛点。按照技术范式的差异，可将其划分为三个核心阶段。

3.1 第一阶段：规则驱动与统计机器学习（1960s—2012年）

这一阶段是文本分类的奠基时代，又可细分为规则时代与统计学习时代。

早期的文本分类完全依赖人工编写的规则与专家词典，比如通过关键词匹配判定垃圾邮件。这类方法在场景单一时精准度高，但扩展性极差，每新增一个类别都需要人工重新编写规则，无法应对海量互联网文本。

随着统计学习理论的成熟，朴素贝叶斯、支持向量机（SVM）、最大熵模型、随机森林等算法逐步成为主流。这类方法不再需要人工编写分类规则，而是通过标注数据自动学习特征到类别的映射关系。其中，SVM凭借在高维稀疏数据上的优异表现，成为这一阶段的标杆算法，在很长时间内都是文本分类任务的工业界首选[4]。

这一阶段的历史贡献是确立了文本分类的标准任务范式，实现了从“全人工”到“数据驱动”的跨越。但其核心瓶颈始终存在：特征工程高度依赖人工，模型只能学习表层统计规律，无法捕捉深层语义与语序关系，性能天花板明显。

3.2 第二阶段：深度学习架构百花齐放（2013—2018年）

词嵌入技术的成熟与GPU算力的普及，推动文本分类快速进入深度学习时代。这一阶段的核心特征是**端到端的自动特征提取**，研究者不再需要手工设计特征，神经网络会自动从原始文本中学习分层的语义表示。

五年间，各类网络架构相继涌现，形成了清晰的演进脉络：

1. 以TextCNN为代表的卷积神经网络，通过滑动卷积核捕捉局部 n 元语法特征，并行计算效率高，在短文本分类任务上表现优异，但对长距离语义依赖的建模能力有限[6]。
2. 以BiLSTM为代表的循环神经网络，天然适配文本的序列属性，能够建模上下文的时序依赖，解决了长距离语义关联问题，但存在串行计算效率低、梯度消失的固有缺陷。
3. 注意力机制的引入，让模型能够自动关注文本中的关键词语，进一步提升了分类的准确率与可解释性，成为后续复杂模型的基础组件。
4. 除此之外，还衍生出了图神经网络、胶囊网络、混合架构等多个分支，分别从不同角度优化文本分类的效果[1]。

深度学习时代彻底打破了传统方法的性能天花板，让复杂语义场景下的分类效果取得了质的飞跃。但这一阶段的方法依然存在局限：绝大多数模型使用静态词向量，无法解决一词多义问题；模型训练高度依赖标注数据，小样本场景下效果不佳。

3.3 第三阶段：预训练语言模型主导的通用范式（2018年至今）

2018年BERT的问世，标志着文本分类进入了预训练大模型时代。这一阶段的核心变革是“预训练+微调”的新范式：模型先在海量无标注文本上进行无监督预训练，学习通用的语言知识与语义表示；再针对具体分类任务，用少量标注数据进行微调，即可得到远超传统深度学习的效果。

从ELMo的上下文动态嵌入，到BERT的自编码预训练，再到GPT系列的自回归大语言模型，预训练模型的参数量从亿级增长至千亿级，涌现出了少样本学习、零样本分类、逻辑推理等传统模型不具备的能力。如今，大语言模型已经成为复杂文本分类任务的首选方案。

但这一范式同样存在新的问题：大模型训练与推理成本高昂，部署门槛高；黑盒属性强，可解释性差；在简单短文本任务上，性价比反而不如传统方法。

4 主流分类方法的多维度对比分析

技术演进不是简单的“后浪淘汰前浪”，不同方法各有其适用边界与优劣势。本节从多个维度对主流方法开展横向对比，为方法选型提供依据。

4.1 传统机器学习方法内部对比

传统机器学习方法至今仍在工业界广泛应用，四类主流算法的核心对比如下：

整体来看，SVM是传统方法中的性能上限，在短稀疏文本场景下甚至能超过部分深度学习模型[2]；朴素贝叶斯与逻辑回归则凭借极致的速度与强可解释性，始终是工业界的基线首选。

4.2 深度学习架构的性能与特性对比

深度学习模型的差异主要体现在架构设计带来的能力侧重不同，并无绝对的优劣之分：

其中，CNN-LSTM这类混合架构能够同时兼顾局部短语特征与全局序列依赖，在多数常规文本分类任务上表现均衡，是深度学习时代的常用工程方案[6]。

Table 1: 传统机器学习分类方法对比

算法	准确率	训练速度	可解释性	小样本表现	核心适用场景
朴素贝叶斯	一般	极快	强	稳定	高实时性过滤、基线模型
逻辑回归	一般	快	强	一般	工业级基线、可解释要求高的场景
SVM	较好	中等	弱	优秀	高维稀疏文本、小样本场景
随机森林	中等	中等	中等	一般	特征维度多、需要快速验证的场景

Table 2: 深度学习分类架构核心特性对比

模型架构	局部特征	长距离依赖	并行效率	参数量级
TextCNN	强	弱	极高	小
BiLSTM	中等	强	低	中等
注意力模型	中等	极强	高	中等
CNN-LSTM混合模型	强	强	中等	中等

4.3 三代技术范式的综合对比

站在整个领域的视角，三代技术范式在核心维度上的差异如下表所示：

Table 3: 三代文本分类技术范式全景对比

技术范式	准确率上限	标注数据依赖	部署成本	可解释性
传统机器学习	中等	中等	极低	强
深度学习	较高	高	中等	弱
预训练大模型	极高	低（少样本）	极高	极弱

可以清晰地看到，准确率的提升往往伴随着可解释性的下降与部署成本的上升，不存在“全维度最优”的方案。

4.4 不同业务场景的方法选型建议

结合上述对比与工程实践，不同场景下的最优方法选择有明确的规律：

1. 高实时性、规则明确的简单过滤场景：优先选择逻辑回归、朴素贝叶斯甚至关键词规则，兼顾速度与可解释性。
2. 短稀疏文本场景（如客服工单、短消息）：优先选择SVM或伯努利朴素贝叶斯，效果不逊于深度学习，推理速度提升数十倍[2]。
3. 中等规模标注数据的通用分类场景：选择TextCNN或BiLSTM等轻量深度学习模型，平衡效果与部署成本。
4. 复杂语义、少样本、高准确率要求的场景：选择预训练语言模型微调，或大模型提示词分类，追求效果上限。

5 个人理解与深度思考

在系统梳理技术路线与方法差异的基础上，结合对领域发展与工程落地的观察，本文提出四点独立思考。

5.1 技术演进的底层逻辑：不断弱化人工依赖

纵观文本分类的三代技术范式，其演进的底层主线非常清晰：****不断将人工工作转移给模型与数据****。规则时代，人要编写全部分类逻辑；统计学习时代，人只需要设计特征，模型学习权重；深度学习时代，人只需要设计网络架构，模型自动学习特征；预训练时代，人只需要定义任务目标，模型已经具备通用语言能力。

人的角色从“规则制定者”逐步退化为“架构设计者”，再退化为“任务引导者”。每一次范式升级，都在进一步降低人类的劳动成本，同时提升模型的能力上限。这不是某一个算法的胜利，而是“数据驱动”替代“人工定义”的必然趋势。

5.2 方法选型的核心：接受“不可能三角”

文本分类领域不存在“准确率最高、速度最快、成本最低”的完美方法，效果、效率、成本构成了天然的“不可能三角”。大模型效果好，但训练推理成本高、延迟高；传统方法效果有上限，但速度快、成本低、可解释性强。

工程落地最忌讳盲目追新。很多业务场景中，一个调优后的SVM模型，准确率只比大模型低2

5.3 对大模型热潮的冷思考：传统方法并未过时

当前大模型是领域热点，很容易形成“大模型万能”的认知误区。但实际上，传统机器学习方法在大量场景中依然具备不可替代的价值：第一，在短文本、高稀疏的简单任务上，传统方法的准确率并不输于中小参数大模型，甚至更稳定；第二，在算力受限的边缘设备、高并发的实时接口中，传统轻量模型是唯一可行的方案；第三，在金融、医疗等高风险场景，传统方法的强可解释性，是黑盒大模型无法替代的核心优势。

大模型拓展了文本分类的能力边界，但并没有否定前两代技术的价值。分层选型、按需搭配，才是理性的工程态度。

5.4 领域发展的未来判断：融合与分层是主线

对于文本分类领域的未来发展，个人认为不会出现“大模型一统天下”的局面，而是会朝着两个方向演进：一是**分层化**，通用复杂任务由大模型承担，垂直简单场景由轻量模型与传统方法承接，各自发挥优势；二是**融合化**，大模型与传统方法会深度结合，比如用大模型做数据增强、特征提取、标签生成，再用轻量分类器完成落地推理，兼顾效果上限与部署成本。

与此同时，可解释性、低资源语言适配、领域知识融合，会是长期的研究痛点与突破方向。

6 当前研究的核心挑战

尽管文本分类技术已经高度成熟，但领域依然存在多个亟待突破的深层瓶颈：

1. **低资源场景适配难**：小众领域、小语种、专业垂直行业的标注数据稀缺，大模型微调效果受限，传统方法泛化能力不足。
2. **模型可解释性缺失**：深度学习与大模型的黑盒属性，让分类决策无法追溯依据，限制了其在高风险领域的深度应用。
3. **复杂语义推理能力弱**：现有模型本质上还是学习文本的统计规律，缺乏基于常识与逻辑的深层推理能力，面对反讽、歧义、多步推理的文本时表现不佳。
4. **大模型落地成本高**：大尺寸预训练模型显存占用大、推理延迟高，难以在高并发、低延迟的工业场景中大规模部署。
5. **对抗鲁棒性不足**：微小的文本扰动就可能导致分类结果反转，模型的安全性与稳定性有待提升。

7 未来重点研究方向

围绕上述挑战，文本分类领域未来的关键突破方向可归纳为六点：

1. 构建覆盖多语言、多领域、多任务的高质量基准数据集，补齐低资源场景的数据短板。
2. 深耕参数高效微调、模型压缩与蒸馏技术，降低大模型的落地门槛与推理成本。
3. 推进可解释性NLP研究，打通模型决策的特征溯源路径，提升模型可信度。
4. 发展少样本、零样本与跨领域迁移技术，进一步降低模型对标注数据的依赖。
5. 融合知识图谱与领域常识，增强模型的逻辑推理与深层语义理解能力。
6. 探索文本分类向多模态综合分类的延伸，融合图像、语音等多源信息提升分类效果。

8 结语

文本分类作为自然语言处理最经典的任务之一，其六十年的演进史，就是整个NLP领域发展的缩影。从人工规则到统计学习，从深度学习到预训练大模型，每一次范式转移都在解决前一代技术的核心痛点，推动着语言理解能力不断向前。

但技术演进从来不是简单的新旧替代。三代方法各有其能力边界与适用场景，不存在绝对的优劣之分。对于研究者而言，既要跟进前沿的大模型技术，也要理解传统方法的价值与逻辑；对于工程实践者而言，更要跳出技术崇拜，根据业务需求选择最适配的方案。未来，随着技术的进一步融合，文本分类必将在效果、效率与可解释性之间找到更好的平衡，支撑更多更复杂的实际应用。

References

- [1] Q. Li, H. Peng, J. Li, et al. A Survey on Text Classification: From Traditional to Deep Learning[J]. ACM Transactions on Intelligent Systems and Technology, 2021, 12(5): 1-41.
- [2] L. Anderlucci, L. Guastadisegni, and C. Viroli. Classifying textual data: shallow, deep and ensemble methods[J]. arXiv preprint arXiv:1902.07068, 2019.
- [3] C. Zhang, B. Peng, X. Sun, et al. From Word Vectors to Multimodal Embeddings: Techniques, Applications, and Future Directions For Large Language Models[J]. arXiv preprint arXiv:2411.05036, 2024.
- [4] E. Şahin, M. Aydos, and F. Orhan. Spam/Ham E-Mail Classification using Machine Learning Methods based on Bag of Words Technique[C]//2018 IEEE 1st Ukraine Conference on Electrical and Computer Engineering (UKRCON). IEEE, 2018: 412-417.
- [5] S. Lai, K. Liu, S. He, and J. Zhao. How to Generate a Good Word Embedding[J]. IEEE Intelligent Systems, 2016, 31(6): 5-14.

- [6] A. Hassan and A. Mahmood. Convolutional Recurrent Deep Learning Model for Sentence Classification[J]. IEEE Access, 2018, 6: 13949-13957.